

王正超

博士生 | 天津大学 | 计算机科学与技术

TEL / 微信: 19591282322 Email: right135@tju.edu.cn 英语水平: CET-4 / CET-6

Agent System Inference

RAG Serving

KVCache Reuse

Workload Analysis



个人简介

研究聚焦 Agent 系统推理、RAG Serving 与 KVCache 复用，具备真实负载分析和大模型应用平台落地经验。

教育背景

天津大学

硕博连读 | 2024.09 - 2030.07

智能与计算学部 | 计算机科学与技术 | 胡一涛教授指导 | Agent System Inference

西北农林科技大学

本科 | 2020.09 - 2024.07

信息工程学院 | 软件工程 | 毛锐副教授指导 | Computer Vision

科研成果

StructSparse: Structure-Aware Prompt Sparsity for Hierarchical KVCache in Agent Serving

提出面向结构化 Agent Prompt 的稀疏感知机制，将 KVCache 按语义重要性分层放置于 HBM/Host/SSD，并结合 RoPE 解耦完成复用判断与请求路由调度，降低 TTFT 与缓存 IO。拟投 ASPLOS。

SuperRAG: Document-oriented KVCache Reuse for Efficient Retrieval-Augmented Generation Serving

提出面向文档的 KVCache 复用机制，降低 RAG Serving 中重复文档上下文带来的推理开销。已投至 ATC。

RAGPULSE: A Real-World RAG Workload Capturing Authentic Temporal Reuse Patterns for Efficient Serving

构建真实 RAG 工作负载，刻画业务场景中的时间复用模式，为缓存与服务调度优化提供数据支撑。已投至 EMNLP。

项目经历

天津大学天问大模型（负责人）

<https://twen.ai/>

- 参与天津大学大模型应用平台建设，围绕智能问答、知识检索、服务推理与应用接入开展系统开发。
- 结合 RAG 与 Agent 能力，支持校园场景下的知识服务、任务处理和多轮交互体验。

天津大学 AI 辅导员“小天老师”（负责人）

智能校园应用

- 参与面向学生服务的 AI 辅导员系统开发，支持校园问答、事务咨询、政策解读和个性化辅助。
- 围绕真实校园业务需求，优化知识组织、问答准确性和交互流程，提升学生获取信息与办理事务的效率。

竞赛与实践

- 2021 年 ACM-ICPC 陕西省大学生程序设计竞赛铜牌。
- 2022 年 ACM-ICPC 陕西省大学生程序设计竞赛银牌。
- 2022 团体程序设计天梯赛全国总决赛个人三等奖。
- 2022 RoboCom 机器人开发者大赛 CAIP 编程设计陕西省赛一等奖、全国总决赛三等奖。
- 2022 年第四届全国高校计算机能力挑战赛 C++ 组全国一等奖。

专业技能

- 熟悉 Agent system infer 与 LLM Serving，关注多轮任务拆解、推理链路编排和服务效率优化。
- 熟悉 真实 LLM workload 与 KVCache 复用分析，能够定位缓存命中、调度策略和服务瓶颈并指导优化。
- 熟悉 Claude、Codex、Copilot 等 vibe coding 工具，能够快速完成系统原型、评测脚本、重构和工程迭代。
- 具备 大模型应用平台 与 智能体应用 建设经验，能够推进需求拆解、功能开发、部署落地和效果验证。